

词处理：统计语言模型





主要内容

- 语言模型
- MM在汉语分词中的应用
- 基于隐马尔科夫模型的词性标注
- OOV识别

隐马尔可夫模型：概述

- 隐马尔可夫模型创建于20世纪70年代，是美国数学家鲍姆等人提出来的。
- 该模型是一个双重随机过程，我们不知道具体的状态序列，只知道状态转移的概率，即模型的状态转换过程是不可观察的（隐蔽的），可观察事件的随机过程是隐蔽状态过程的随机函数。

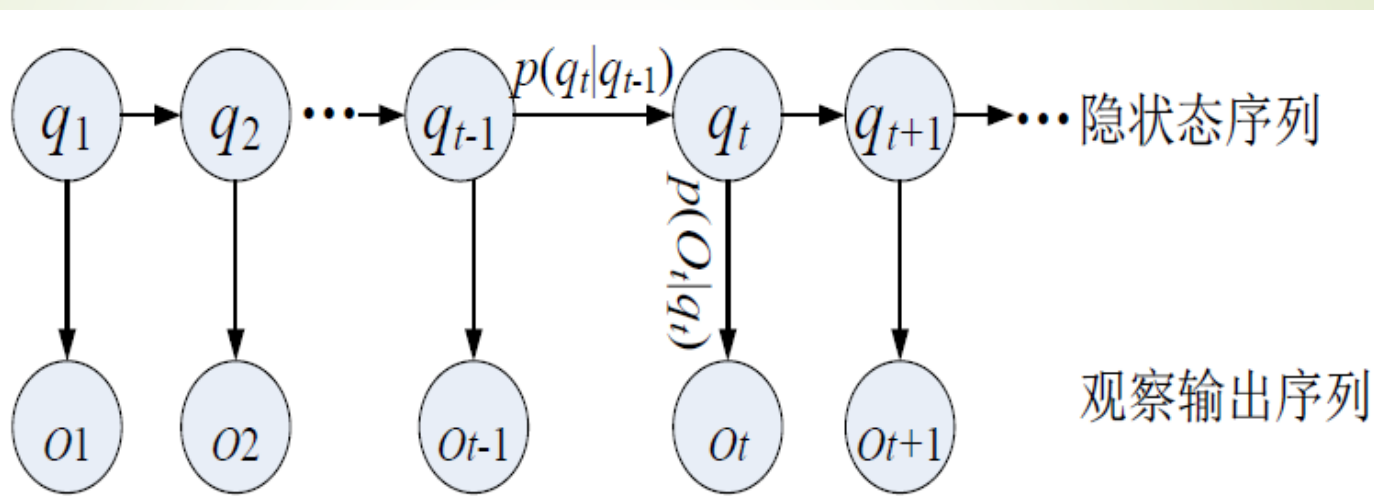
隐马尔可夫模型：例子

- 假定一暗室中有 N 个口袋，每个口袋中有 M 种不同颜色的球。
- 一个实验员根据某一概率分布随机地选取一个初始口袋，从中根据不同颜色的球的概率分布，随机地取出一个球，并向室外的人报告该球的颜色。
- 再根据口袋的概率分布选择另一个口袋，根据不同颜色的球的概率分布从中随机选择另外一个球。重复进行这个过程。

隐马尔可夫模型：例子

- 对于暗室外边的人来说，可观察的过程只是不同颜色的球的序列，而口袋的序列是不可观察的。
- 每个口袋对应于HMM中的状态，球的颜色对应于HMM中状态的输出符号。
- 从一个口袋转向另一个口袋对应于状态转换，从口袋中取出球的颜色对应于从一个状态输出的观察符号。

隐马尔可夫模型：图解



HMM 图解

隐马尔可夫模型：组成部分

1. 模型中状态的数目 N （上例中口袋的数目）；
2. 从每个状态可能输出的不同符号的数目 M （上例中球的不同颜色的数目）；
3. 状态转移概率矩阵 $A = \{a_{ij}\}$ （ a_{ij} 为实验员从一个口袋（状态 s_i ）转向另一个口袋（ s_j ）取球的概率）。其中：

$$a_{ij} = P(q_t = s_j | q_{t-1} = s_i), 1 \leq i, j \leq N$$

$$a_{ij} \geq 0$$

$$\sum_{j=1}^N a_{ij} = 1$$

隐马尔可夫模型：组成部分

4. 从状态 s_j 观察到符号 v_k 的概率分布矩阵 $B = \{b_j(k)\}$ （ $b_j(k)$ 为实验员从第 j 个口袋中取出第 k 种颜色的球的概率），其中：

$$b_j(k) = P(O_t = v_k | q_t = s_j), 1 \leq j \leq N; 1 \leq k \leq M$$

$$b_j(k) \geq 0$$

$$\sum_{k=1}^M b_j(k) = 1$$

隐马尔可夫模型：组成部分

5. 初始状态概率分布 $\pi = \{\pi_i\}$ ，其中：

$$\pi_i = P(q_1 = s_i), 1 \leq i \leq N$$

$$\pi_i \geq 0$$

$$\sum_{i=1}^N \pi_i = 1$$

隐马尔可夫模型：组成部分

- 一般地，一个HMM记为一个五元组 $\mu = (S, K, A, B, \pi)$ ，其中， S 为状态的集合， K 为输出符号的集合， π ， A 和 B 分别是初始状态的概率分布、状态转移概率和符号发射概率。
- 为了简单，有时也将其记为三元组 $\mu = (A, B, \pi)$

隐马尔可夫模型：三个基本问题


1. 估计问题：给定一个观察序列 $O = O_1 O_2 \dots O_T$ 和模型 $\mu = (A, B, \pi)$ ，如何快速地计算出给定模型 μ 情况下，观察序列 O 的概率，即 $P(O|\mu)$ ？
2. 序列问题：给定一个观察序列 $O = O_1 O_2 \dots O_T$ 和模型 $\mu = (A, B, \pi)$ ，如何快速有效的选择在一定意义下“最优”的状态序列 $Q = q_1 q_2 \dots q_T$ ，使得该状态序列“最好的解释”观察序列？
3. 参数估计问题：给定一个观察序列 $O = O_1 O_2 \dots O_T$ ，如何根据最大似然估计来求模型的参数值？即如何调节模型 $\mu = (A, B, \pi)$ 的参数，使得 $P(O|\mu)$ 最大？

隐马尔可夫模型：求解观察序列的概率

- 给定观察序列 $O = O_1 O_2 \dots O_T$ 和模型 $\mu = (A, B, \pi)$ ，快速的计算出给定模型 μ 情况下观察序列 O 的概率，即 $P(O|\mu)$ 。
- 将其称为解码问题。
- 对于给定的状态序列 $Q = q_1 q_2 \dots q_T$, $P(O|\mu) = ?$
- $p(O|\mu) = \sum_Q p(O, Q|\mu) = \sum_Q p(Q|\mu) \cdot p(O|Q, \mu)$
- $p(Q|\mu) = \pi_{q_1} a_{q_1 q_2} a_{q_2 q_3} \dots a_{q_{T-1} q_T}$
- $p(O|Q, \mu) = b_{q_1}(O_1) b_{q_2}(O_2) \dots b_{q_T}(O_T)$

隐马尔可夫模型：求解观察序列的概率

- 存在的困难：如果模型 μ 有 N 个不同的状态，时间长度为 T ，那么有 N^T 个可能的状态序列，搜索路径成指数级组合爆炸。



隐马尔可夫模型：前向算法

- 解决办法：动态规划，前向算法。
- 基本思想：定义前向变量 $\alpha_t(i)$ ，前向变量 $\alpha_t(i)$ 是在时间 t ，HMM输出了序列 $O_1 O_2 \dots O_t$ ，并且位于状态 s_i 的概率。
- $\alpha_t(i) = P(O_1 O_2 \dots O_t, q_t = s_i | \mu)$
- 如果可以高效的计算 $\alpha_t(i)$ ，就可以高效的求得 $p(O | \mu)$ 。

隐马尔可夫模型：前向算法


- $p(O|\mu)$ 是在到达状态 q_T 时观察到序列 $O = O_1 O_2 \dots O_T$ 的概率：

$$p(O|\mu) = \sum_{s_i} p(O_1 O_2 \dots O_T, q_T = s_i | \mu) = \sum_{i=1}^N \alpha_T(i)$$

- 在时间 $t+1$ 的前向变量可以根据在时间 t 时的前向变量 $\alpha_t(1), \alpha_t(2) \dots \alpha_t(N)$ 的值来归纳计算

$$\alpha_{t+1}(j) = \left(\sum_{i=1}^N \alpha_t(i) a_{ij} \right) b_j(O_{t+1})$$

隐马尔可夫模型：前向算法



隐马尔可夫模型：前向算法

前向算法

1. 初始化： $\alpha_1(i) = \pi_i b_i(O_1), 1 \leq i \leq N$ 。

2. 归纳计算

$$\alpha_{t+1}(j) = \left(\sum_{i=1}^N \alpha_t(i) a_{ij} \right) b_j(O_{t+1}), 1 \leq t \leq T - 1$$

3. 求和终结

$$P(O|\mu) = \sum_{i=1}^N \alpha_T(i)$$

隐马尔可夫模型：前向算法

- ▶ 时间复杂度：
- ▶ 每计算一个 $\alpha_t(i)$ 必须考虑从 $t-1$ 时的所有 N 个状态转移到状态 s_i 的可能性，时间复杂度为 $O(N)$ ，对应每一个时刻 t ，要计算 N 个前向变量： $\alpha_t(1), \alpha_t(2), \dots, \alpha_t(N)$ ，所以，时间复杂度为： $O(N) \times N = O(N^2)$ ，
- ▶ 又因为 $t=1, 2, \dots, T$ ，所以前向算法总的复杂度为 $O(N^2T)$

隐马尔可夫模型：后向算法

- 后向变量 $\beta_t(i)$ 是在给定模型 $\mu = (A, B, \pi)$ ，并且在时间 t 状态为 s_i 的条件下，HMM输出观察序列 $O_{t+1} \dots O_T$ 的概率。
- $\beta_t(i) = P(O_{t+1} \dots O_T | q_t = s_i, \mu)$

隐马尔可夫模型：后向算法

- 与计算前向变量一样，可以用动态规划的算法计算后向变量。
- 1. 从时刻 t 到 $t+1$ ，模型由状态 S_i 转移到状态 S_j ，并从 S_j 输出 O_{t+1}
- 2. 在时间 $t+1$ ，状态为 S_j 的条件下，模型输出观察序列 $O_{t+2}O_{t+3} \dots O_T$


隐马尔可夫模型：后向算法

- 第一步的概率： $a_{ij} \times b_j(O_{t+1})$
- 第二步的概率按后向变量的定义为 $\beta_{t+1}(i)$
- 可得到如下归纳关系：

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)$$

- 归纳顺序为： $\beta_T(x), \beta_{T-1}(x), \dots, \beta_1(x)$

隐马尔可夫模型：后向算法



隐马尔可夫模型：后向算法

1. 初始化： $\beta_T(i) = 1, 1 \leq i \leq N$

2. 归纳计算：

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), T-1 \geq t \geq 1; 1 \leq i \leq N$$

3. 求和终结：

$$P(O|\mu) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$$

时间复杂度： $O(N^2T)$

隐马尔可夫模型：维特比算法

- 维特比算法用于求解HMM中的第二个问题，给定一个观察序列 $O = O_1 O_2 \dots O_T$ 和模型 $\mu = (A, B, \pi)$ ，如何快速有效的选择在一定意义下最优的状态序列 $Q = q_1 q_2 \dots q_T$ ，使得该状态序列“最好的解释”观察序列。
- 对于最优状态序列的一种理解：状态序列中的每个状态都单独的具有概率，对于每个时刻 $t (1 \leq t \leq T)$ ，寻找 q_t 使得 $\gamma_t(i) = p(q_t = S_i | O, \mu)$ 最大。

隐马尔可夫模型：维特比算法

$$\gamma_t(i) = p(q_t = S_i | O, \mu) = \frac{p(q_t = S_i, O | \mu)}{p(O | \mu)}$$

- $p(q_t = S_i, O | \mu)$ 表示模型的输出序列 O ，并在时间 t 到达状态 i 的概率。

隐马尔可夫模型：维特比算法

- 分解过程：
- 模型在时间 t 到达状态 i ，并且输出 $O = O_1 O_2 \dots O_T$ 。根据前向变量的定义，实现这一步的概率为 $\alpha_t(i)$ 。
- 从时间 t ，状态 S_i 出发，模型输出 $O = O_1 O_2 \dots O_T$ ，根据后向变量定义，实现这一部的概率为 $\beta_t(i)$ 。
- 因此：
- $p(q_t = S_i, O | \mu) = \alpha_t(i) \times \beta_t(i)$

隐马尔可夫模型：维特比算法

- 而 $p(O|\mu)$ 与时间 t 的状态无关，因此：

$$p(O|\mu) = \sum_{i=1}^N \alpha_t(i) \times \beta_t(i)$$


- 因此： $\gamma_t(i) = \frac{\alpha_t(i) \times \beta_t(i)}{\sum_{i=1}^N \alpha_t(i) \times \beta_t(i)}$

- t 时刻的最优状态为： $\hat{q}_t = \arg \max_{1 \leq i \leq N} (\gamma_t(i))$


隐马尔可夫模型：维特比算法

- 存在问题：
- 每一个状态单独最优不一定整体的状态序列最优，可能两个最优的状态 \hat{q}_t \hat{q}_{t+1} 之间的转移概率为0.


隐马尔可夫模型：维特比算法



隐马尔可夫模型：维特比算法



隐马尔可夫模型：维特比算法



隐马尔可夫模型：维特比算法

- 对于最优的另一种解释：在给定模型 μ 和观察序列 O 的条件下，使得 $P(Q|O, \mu)$ 最大。
- $Q' = \operatorname{argmax}_Q P(Q|O, \mu)$
- 维特比算法运用动态规划的搜索算法求解最优状态序列。
- 定义一个维特比变量。
- 维特比变量 $\delta_t(i)$ 是在时间 t 时，HMM 沿着某一条路径到达状态 s_i ，并输出观察序列 $O_1 O_2 \dots O_t$ 的最大概率。

隐马尔可夫模型：维特比算法

- $\delta_t(i) = \max_{q_1, q_2 \dots q_{t-1}} P(q_1, q_2 \dots q_t = s_i, O_1 O_2 \dots O_t | \mu)$

- 与前向变量类似， $\delta_t(i)$ 有如下递归关系：

- $\delta_{t+1}(i) = \max_j [\delta_t(j) \cdot a_{ji}] \cdot b_i(O_{t+1})$

隐马尔可夫模型：维特比算法

步1 初始化：

$$\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$$

$$\psi_1(i) = 0$$

步2 归纳计算：

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T; 1 \leq j \leq N$$

记忆回退路径：

$$\psi_t(j) = \operatorname{argmax}_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T; 1 \leq i \leq N$$

步3 终结：

$$\hat{Q}_T = \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)]$$

$$\hat{P}(\hat{Q}_T) = \max_{1 \leq i \leq N} [\delta_T(i)]$$


步4 路径（状态序列）回溯：

$$\hat{q}_t = \psi_{t+1}(\hat{q}_{t+1}), \quad t = T-1, T-2, \dots, 1$$

时间复杂度为 $O(N^2T)$

隐马尔可夫模型：维特比算法

图解
Viterbi
搜索过程




隐马尔可夫模型：维特比算法

图解
Viterbi
搜索过程

剪枝策略：

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$




隐马尔可夫模型：维特比算法

图解
Viterbi
搜索过程

剪枝策略：

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$




隐马尔可夫模型：维特比算法

图解
Viterbi
搜索过程

剪枝策略：

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$




隐马尔可夫模型：维特比算法

图解
Viterbi
搜索过程

剪枝策略：

- ① $\delta_t(j) \geq \Delta$
- ② $NPath \leq \sigma$



隐马尔可夫模型：参数估计

- 参数估计是HMM面临的第三个问题，给定观察序列 $O = O_1 O_2 \dots O_T$ ，如何调节模型 $\mu = (A, B, \pi)$ 的参数，使得 $P(O|\mu)$ 最大。

$$\operatorname{argmax}_{\mu} P(O_{\text{training}}|\mu)$$

- 模型的参数是指构成 μ 的 $\pi_i, a_{ij}, b_j(k)$ 。

隐马尔可夫模型：参数估计

- 如果产生观察序列 O 的状态 $Q = q_1 q_2 \dots q_T$ 已知，可以用最大似然估计来计算 μ 的参数：

- $\pi'_i = \delta(q_1, S_i)$

- $a'_{ij} =$

$$\frac{\text{q中从状态} q_i \text{转移到} q_j \text{的次数}}{\text{q中所有从状态} q_i \text{转移到另一状态（包括} q_j \text{自身）的总数}} = \frac{\sum_{t=1}^{T-1} \delta(q_t, S_i) \times \delta(q_{t+1}, S_j)}{\sum_{t=1}^{T-1} \delta(q_t, S_i)}$$

- 其中， $\delta(x, y)$ 为克洛耐克(kronecker)函数，当 $x=y$ 时， $\delta(x, y)=1$ ，否则 $\delta(x, y)=0$

隐马尔可夫模型：参数估计

➤ 类似的

➤ $b'_j(k) = \frac{\text{q中从状态 } q_j \text{ 输出符号 } v_k \text{ 的次数}}{\text{q到达 } q_j \text{ 的总次数}}$

$$= \frac{\sum_{t=1}^T \delta(q_t, s_j) \times \delta(o_t, v_k)}{\sum_{t=1}^T \delta(q_t, s_j)}$$

➤ 其中， v_k 是模型输出符号集中的第k个符号。

隐马尔可夫模型：参数估计


- ▶ 期望值最大化算法 (EM)
- ▶ 初始化时随机的给模型的参数赋值，遵循限制规则，例如：从某一状态出发的转移概率总和为1，得到模型 μ_0 ，然后可以从 μ_0 得到从某一状态转移到另一状态的期望次数，然后以期望次数代替公式中的次数，得到模型参数的新估计，由此得到新的模型 μ_1 ，从 μ_1 又可以得到模型中隐变量的期望值，由此重新估计模型参数。循环这个过程，参数收敛于最大似然估计。

隐马尔可夫模型：参数估计

- 给定模型 μ 和观察序列 $O = O_1 O_2 \dots O_T$ ，在时间 t 位于状态 S_i ，时间 $t+1$ 位于状态 S_j 的概率：

$$\begin{aligned}\xi_t(i, j) &= p(q_t = S_i, q_{t+1} = S_j | O, \mu) \\ &= \frac{p(q_t = S_i, q_{t+1} = S_j, O | \mu)}{p(O | \mu)} \\ &= \frac{\alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)}{p(O | \mu)} \\ &= \frac{\alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) \times a_{ij} b_j(O_{t+1}) \times \beta_{t+1}(j)} \quad (6-24)\end{aligned}$$

隐马尔可夫模型：参数估计



隐马尔可夫模型：参数估计

- 因此，给定模型 μ 和观察序列 $O = O_1 O_2 \dots O_T$ ，在时间 t 位于状态 S_j 的概率为：

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i, j) \quad (6-25)$$

- 因此，模型 μ 的参数可由下面的公式重新估计：

1. q_1 为 S_i 的概率：

$$\pi_i = \gamma_1(i) \quad (6-26)$$

隐马尔可夫模型：参数估计

2.

a'_{ij}

$= \frac{Q \text{中从状态 } q_i \text{ 转移到 } q_j \text{ 的期望次数}}{Q \text{中所有从状态 } q_i \text{ 转移到另一状态（包括 } q_j \text{ 自身）的期望总数}}$

$$= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (6-27)$$

隐马尔可夫模型：参数估计

3. $b'_j(k) = \frac{\text{q中从状态} q_j \text{输出符号} v_k \text{的期望次数}}{\text{q到达} q_j \text{的期望次数}}$

$$= \frac{\sum_{t=1}^T \gamma_t(j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \gamma_t(j)} \quad (6-28)$$

隐马尔可夫模型：前向后向算法

步1 初始化：随机地给参数 π_i , a_{ij} , $b_j(k)$ 赋值, 使其满足如下约束:

$$\sum_{i=1}^N \pi_i = 1$$

$$\sum_{j=1}^N a_{ij} = 1, \quad 1 \leq i \leq N$$

$$\sum_{k=1}^M b_j(k) = 1, \quad 1 \leq j \leq N$$

由此得到模型 μ_0 。令 $i=0$, 执行下面的EM估计。

步2 EM计算:

E-步骤: 由模型 μ_i 根据式(6-24)和式(6-25)计算期望值 $\xi_t(i,j)$ 和 $\gamma_t(i)$;

M-步骤: 用E-步骤得到的期望值, 根据式(6-26)、(6-27)和(6-28)重新估计参数 π_i , a_{ij} , $b_j(k)$ 的值, 得到模型 μ_{i+1} 。

步3 循环计算:

令 $i=i+1$ 。重复执行EM计算, 直到 π_i , a_{ij} , $b_j(k)$ 收敛。

隐马尔可夫模型：应用举例

- 词性标注问题。
- 例如：武汉市长江大桥于1957年9月6日竣工。

武汉/N 市长/N 江大桥/N 于/P 1957年9月6日/Time
竣工/V 。/Pun

隐马尔可夫模型：应用举例

- 用HMM解决问题必须考虑的几个问题：
 - 1. 如何确定状态、观察及各自的数目？
 - 2. 参数估计：初始状态概率、状态转移概率、输出概率如何确定？

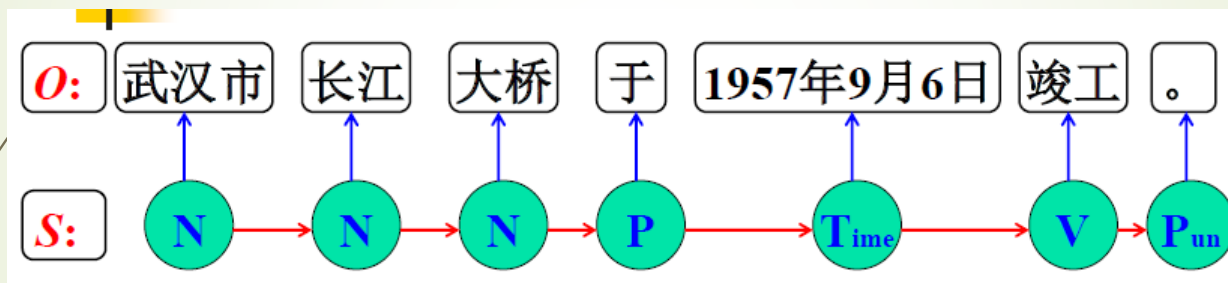
隐马尔可夫模型：应用举例

- 对于汉语分词：如果将汉语分词的结果作为观察序列 $O = O_1 O_2 \dots O_T$ ，那么则需求解 $O' = \operatorname{argmax}_O P(O|\mu)$ 。
- 对于词性标注问题：则需要求解的是：
 $Q' = \operatorname{argmax}_Q P(Q|O, \mu)$ 。

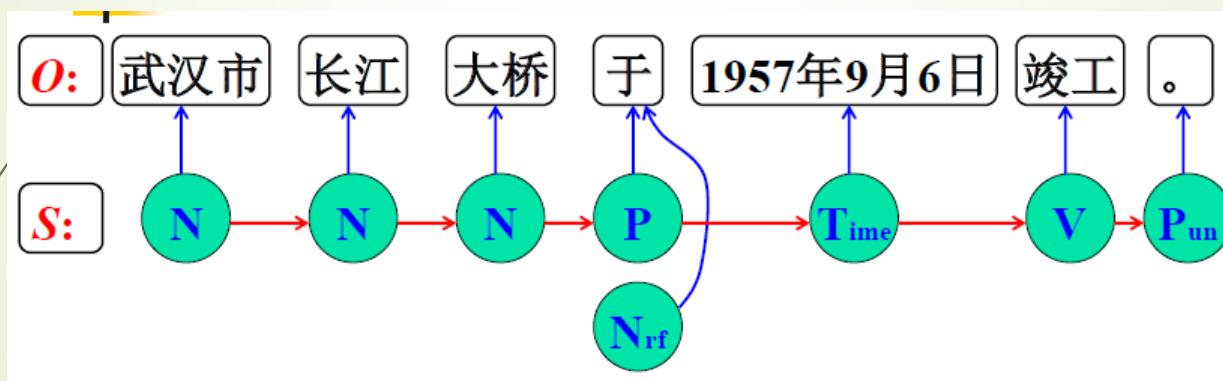
隐马尔可夫模型：应用举例

- 进一步解释：
- 估计HMM模型 $\mu = (A, B, \pi)$ 的参数。
- 对于任意给定的一个输入句子及其可能的输出序列 O ，求找所有可能的 O 中使概率 $p(O|\mu)$ 最大的解。
- 快速的选择“最优”的状态序列(词性序列)，使其最好的解释观察序列。

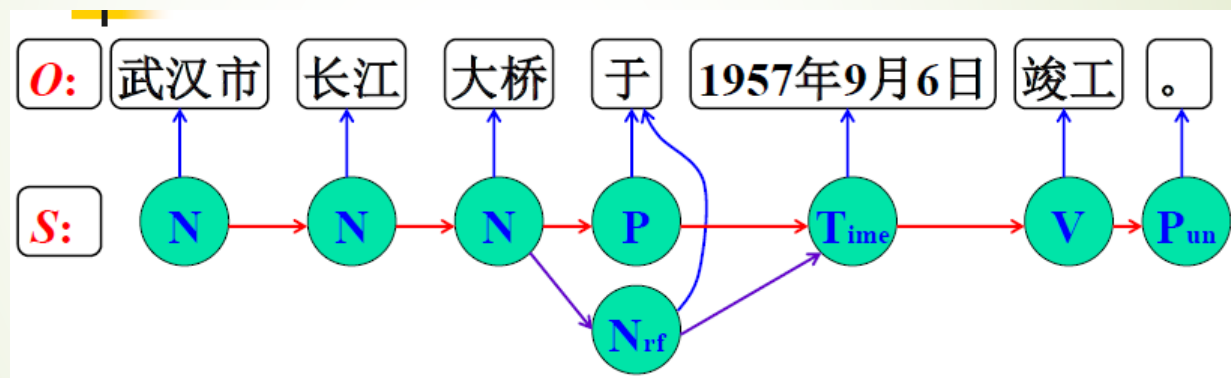
隐马尔可夫模型：应用举例



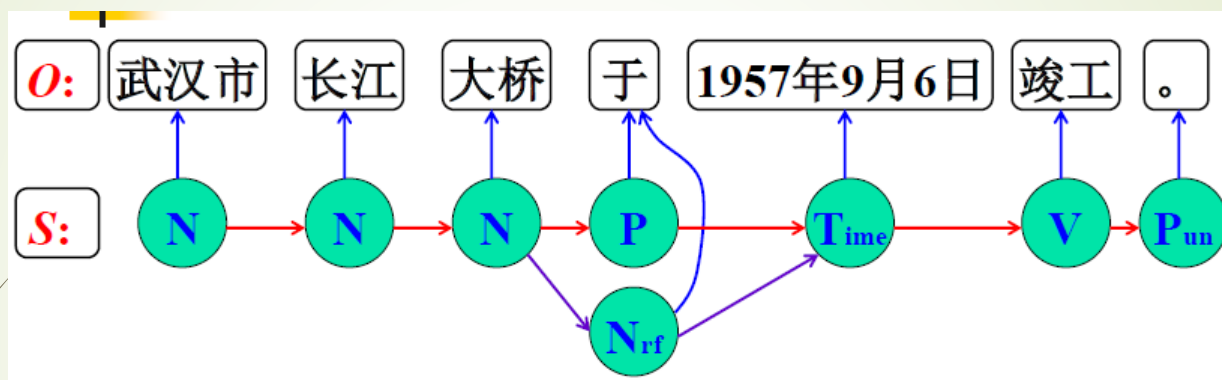
隐马尔可夫模型：应用举例



隐马尔可夫模型：应用举例



隐马尔科夫模型：应用举例



a.武汉市/N 长江/N 大桥/N 于/P 1957年9月6日/Time

竣工/V 。 /Pun

b.武汉市/N 长江/N 大桥/N 于/ N_{rf} 1957年9月6日/Time

竣工/V 。 /Pun

隐马尔科夫模型：应用举例

- 问题1：模型参数
- 观察序列：单词序列。
- 状态序列：词类标记序列。
- 状态数目N：为词类标记符号的个数，如Upenn LDC汉语树库中有33个词类，北大语料库词类标记符号106个等。
- 输出符号数M：每个状态可输出的不同词汇个数，如汉语介词P约有60个，连词C约有110个，即状态P和C对应的输出符号数为60、110。

隐马尔可夫模型：应用举例

- 参数估计：
- 如果无任何标注语料：需要一部有词性标注的词典，采用无指导学习方法：
 - 获取词类个数（状态数）
 - 获取对应每种词类的词汇数（输出符号数）
 - 利用EM迭代算法获取初始状态概率、状态转移概率和输出符号概率。

隐马尔可夫模型：应用举例

- 若有大规模分词和词性标注语料：有指导学习方法。

咱们/r r 中国/n s 这么/r z 大{da4}/a 的{de5}/u d 一个/m q
多/a 民族/n 的{de5}/u d 国家/n 如果/c 不/d f 团结/a ,
/w d 就/d 不/d f 可能/v u 发展/v 经济/n , /w d 人民/n
生活/n 水平/n 也/d 就/d 不/d f 可能/v u 得到/v 改善/v n
和{he2}/c 提高/v n 。 /w j

- 可以从这些标注语料中抽取所有的词汇和词类标记，并用最大似然估计方法计算各种概率。

隐马尔可夫模型：应用举例

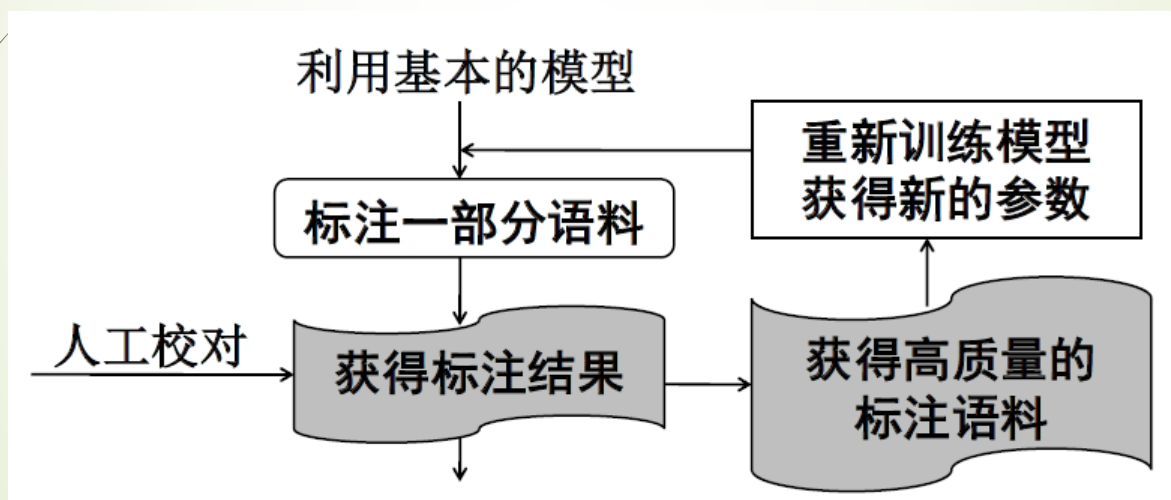
$$\bar{\pi}_{\text{pos}_i} = \frac{\text{POS}_i \text{出现在句首的次数}}{\text{所有句首的个数}}$$

$$\bar{a}_{ij} = \frac{\text{从词类POS}_i \text{转移到POS}_j \text{的次数}}{\text{所有从状态POS}_i \text{转移到另一POS(包括POS}_j \text{)的总数}}$$

$$\bar{b}_j(k) = \frac{\text{从状态POS}_j \text{输出词汇} w_k \text{的次数}}{\text{状态POS}_j \text{出现的总次数}}$$

隐马尔可夫模型：应用举例

- 一般来说，需要通过错误驱动的机器学习方法修正模型的参数。



隐马尔可夫模型：应用举例

➤ 问题2：如何获取观察序列？

➤ 借助其他工具，获得n-best的粗切分。

本地主叫通话时长1400分钟。

——> 本地/ 主叫/ 通话/ 时长/ 1400/ 分钟/ 。
本/ 地主/ 叫/ 通话/ 时/ 长/ 1400/ 分钟/ 。
本/ 地主/ 叫/ 通话/ 时长/ 1400/ 分钟/ 。

负责任 ——> 负/ 责任
负责/ 任
负/ 责/ 任